Módulo II: Series aleatorias

Diseño de modelos de simulación

4º Curso, 1er. Cuatrimestre - Grado en Ingeniería informática

Escuela Politécnica Superior de Jaén

Curso 2026-27

uja.
Universidad de Jaén

Módulo II: Series aleatorias

- **Tema 3: Modelado de las distribuciones de probabilidad de entrada**
- Tema 4: Generación de series aleatorias
- Tema 5: Generación de observaciones de variables aleatorias

uja. Universidad de Jaén

Tema 3: Modelado de las distribuciones de probabilidad de entrada

- **Introducción**
- Selección de la familia de distribuciones
- Estimación de los parámetros
- Medida de la bondad del ajuste
- Selección de la distribución en ausencia de datos

uja. Universidad de Jaén

Introducción

- Es preciso disponer de datos con los que "alimentar" el modelo durante la simulación:
  - tiempos entre llegadas consecutivas de las entidades, tiempos de proceso,
  - tiempos entre fallos de los recursos,
  - porcentaje de entidades que fallan cierto criterio,
  - Etc.

Introducción

- La adecuada selección de los datos de entrada es tan importante para el éxito del estudio como lo son la construcción del modelo o el posterior análisis de los resultados.
- La decisión sobre la forma de generar las observaciones de cada variable aleatoria de entrada durante la simulación es una hipótesis de modelado, que se realiza basándose en consideraciones teóricas, datos medidos del sistema, etc.
- Aunque la estructura del modelo sea válida, si los datos de entrada no han sido recogidos y analizados adecuadamente, o no son representativos, entonces los resultados obtenidos de la simulación no serán correctos, y las decisiones tomadas en base a ellos serán erróneas.

Introducción

- La recogida de los datos experimentales del sistema es una de las tareas más costosas y delicadas en el proceso de modelado.

Introducción

- Cuando se dispone de muestras experimentales de la variable aleatoria de entrada, podemos aplicar tres técnicas:
  - *Usar directamente los datos en la simulación*. Por ejemplo, si los datos representan el tiempo entre fallos de una máquina, entonces se usa uno de estos datos cada vez que se necesita un intervalo entre fallos en la simulación.

Introducción

- Cuando se dispone de muestras experimentales de la variable aleatoria de entrada, podemos aplicar tres técnicas:
  - *Definir una distribución empírica a partir de los datos experimentales*. Por ejemplo, si los datos representan el tiempo entre fallos, se muestreará de esta distribución cuando se necesite un tiempo entre fallos en la simulación.

Introducción

- Cuando se dispone de muestras experimentales de la variable aleatoria de entrada, podemos aplicar tres técnicas:
  - *Ajustar una distribución teórica a los datos experimentales*. El proceso de ajuste consta de los tres pasos siguientes:
    1. En primer lugar se selecciona la familia de la distribución (exponencial, normal, de Poisson, etc.).
    2. A continuación se calcula qué valor de los parámetros de la familia de distribuciones proporciona el mejor ajuste a los datos. Con ello se selecciona una única distribución de la familia de distribuciones.
    3. Finalmente, se aplica un criterio para determinar la bondad del ajuste. Este criterio permite decidir, entre varias distribuciones, cuál es más representativa de los datos experimentales.

Introducción

- El procedimiento comúnmente más aceptado consiste en tratar en primer lugar de modelizar la probabilidad de la variable de entrada mediante una distribución teórica, recurriendo a las distribuciones empíricas sólo como último recurso.

Introducción

- Dicha elección se debe a que:
  - La forma de las distribuciones empíricas puede ser considerablemente irregular, particularmente cuando se dispone de un número pequeño de datos.
  - Sin embargo, en ocasiones la naturaleza del fenómeno que se está modelando no justifica estas irregularidades, que más bien son debidas a la propia naturaleza aleatoria de la recogida de datos del sistema.
  - En estos casos puede ser preferible modelar el fenómeno "suavizando" los datos, mediante una distribución teórica.

Introducción

- Dicha elección se debe a que:
  - En aquellos casos en que existan fundamentos teóricos para modelar determinado fenómeno usando una determinada familia teórica de distribuciones, suele ser recomendable usar ese tipo de distribución teórica ajustada a los datos experimentales.
  - No hay que olvidar que los datos experimentales recogidos son, en sí, aleatorios, con lo cual, una distribución empírica, obtenida a partir de un conjunto de observaciones, puede diferir mucho de la obtenida a partir de otro conjunto de observaciones del mismo proceso.

Introducción

- Dicha elección se debe a que:
  - Las distribuciones teóricas son una forma compacta de representar los datos.
  - Si se dispone de n valores experimentales, la distribución empírica está definida mediante 2n valores: los datos y las correspondientes probabilidades acumuladas.
  - Si el conjunto de datos es grande, el almacenamiento de los datos puede ser una dificultad añadida.

Tema 3: Modelado de las distribuciones de probabilidad de entrada

- Introducción
- **Selección de la familia de distribuciones**
- Estimación de los parámetros
- Medida de la bondad del ajuste
- Selección de la distribución en ausencia de datos

uja. Universidad de Jaén

Selección de la familia de distribuciones

- Supongamos que se pretende emplear una distribución de probabilidad teórica para modelar una entrada aleatoria de la simulación.
- El primer paso en la selección de la distribución teórica es decidir qué familia de distribuciones parece más apropiada.
- Esta decisión se toma en base al análisis de la forma de la distribución, sin tener en cuenta, por el momento, el valor de los parámetros de la distribución.

Selección de la familia de distribuciones

- En ocasiones, se dispone a priori del suficiente conocimiento acerca del proceso a modelar como para poder seleccionar una familia de distribuciones, o al menos para poder descartar algunas otras.
- Recomendaciones sobre el uso de algunas distribuciones teóricas continuas:
  - *Uniforme*. Resulta adecuada cuando la entrada toma con igual probabilidad cualquier valor de cierto intervalo.
    - Se usa como primera aproximación para una variable que se supone que varía aleatoriamente en determinado intervalo, y de la que no se sabe nada más.

Selección de la familia de distribuciones

- Recomendaciones sobre el uso de algunas distribuciones teóricas continuas:
  - *Triangular*. Se usa como primera aproximación en ausencia de datos, cuando se pretende representar un proceso para el cual pueden establecerse unos límites (*mínimo* y *máximo*) y el valor más probable (*modo*).
  - *Gamma*. Suele emplearse para modelar el tiempo necesario para completar una tarea.
    - Esta distribución puede tomar una gran variedad de formas, en función del valor de su parámetro de forma.

Selección de la familia de distribuciones

- Recomendaciones sobre el uso de algunas distribuciones teóricas continuas:
  - *Exponencial*. Se usa para representar el intervalo de tiempo entre eventos independientes, por ejemplo, la llegada de entidades al sistema.
    - Si el número de eventos por intervalo de tiempo es una variable aleatoria discreta de Poisson de media λ, entonces los intervalos de tiempo entre llegadas están distribuidos exponencialmente con media $\beta = 1/\lambda$
    - Cuando la variable aleatoria representa un intervalo de tiempo, la distribución exponencial posee una propiedad única: no tiene memoria.
  - *Weibull*. Se usa en los modelos de fiabilidad, para representar los tiempos de vida (tiempo hasta el fallo) de dispositivos en los cuales el uso afecta a su tiempo esperado de vida (dispositivos eléctricos, muelles, etc.). En ocasiones, se usa también para representar el tiempo necesario para completar una tarea.

Selección de la familia de distribuciones

- Recomendaciones sobre el uso de algunas distribuciones teóricas continuas:
  - *Normal*. Se emplea para describir fenómenos que son suma o promedio de una gran cantidad de variables aleatorias independientes entre sí, y tales que cada una de ellas realiza una pequeña contribución a la suma (*Teorema del Límite Central*).
    - Por ejemplo, si se reemplazan los tiempos de proceso de varios subprocesos independientes por un único tiempo de proceso, que es la suma de aquellos, el tiempo de proceso resultante tiene una distribución que se aproxima a la normal al aumentar el número de subprocesos.
    - Esto se cumple con independencia de qué distribuciones de probabilidad tengan los tiempos de los subprocesos.

Selección de la familia de distribuciones

- Recomendaciones sobre el uso de algunas distribuciones teóricas discretas:
  - *Bernoulli*. La variable aleatoria representa el resultado de un experimento con dos únicos posibles resultados.
  - *Uniforme discreta*. La variable aleatoria es el resultado de un experimento con varios posibles resultados, todos ellos igualmente probables.

Selección de la familia de distribuciones

- Recomendaciones sobre el uso de algunas distribuciones teóricas discretas:
  - *Binomial*. Es adecuada cuando se pretende estudiar el número de miembros de un grupo de individuos que poseen cierta característica.
    - El grupo de individuos ha sido escogido aleatoriamente, y posee un tamaño fijo, conocido a priori.
    - Cada individuo tiene la misma probabilidad de poseer la característica.
    - El hecho de que un individuo posea la característica es independiente del hecho de que otro la posea: saber que ciertos individuos poseen la característica no ayuda a decidir si otro individuo en concreto la tiene.

Selección de la familia de distribuciones

- Recomendaciones sobre el uso de algunas distribuciones teóricas discretas:
  - *Geométrica*. Es aplicable cuando se pretende estudiar el número de repeticiones de un experimento de Bernoulli que deben hacerse hasta que se produce uno determinado de los dos posibles resultados.
  - *Negativa binomial*. Es adecuada para describir el numero de experimentos de Bernoulli "fallidos" antes de que se dé, un determinado número de veces, uno determinado de los dos posibles resultados.
  - *Poisson*. Es adecuada para modelizar el número de eventos aleatorios que suceden en un intervalo de tiempo fijo.

Selección de la familia de distribuciones

- Estadísticos:
  - Los valores de algunos estadísticos de la muestra experimental, como son la media, la mediana, la varianza, etc. pueden guiar en la elección de la familia de la distribución.
  - En cualquier caso, debe tenerse presente que el valor del estadístico calculado de la muestra es una observación aleatoria, es decir, el valor calculado no coincide (en general) con el valor verdadero del estadístico de la distribución.
  - En conclusión, estos métodos tienen sólo carácter orientativo y en ningún caso proporcionan información definitiva.

Selección de la familia de distribuciones

- Histogramas:
  - El histograma es básicamente una estimación gráfica de la densidad de probabilidad de los datos experimentales, x_1, ..., x_n.
  - Las funciones densidad de probabilidad de las distribuciones teóricas tienen formas reconocibles, con lo cual, el histograma sirve de ayuda para seleccionar qué familia o familias de distribuciones tiene sentido emplear para modelar el proceso de entrada.
  - Para ello debe compararse la forma del histograma con la forma de la distribución teórica, sin considerar la escala o la posición.

Selección de la familia de distribuciones

- Gráficas Cuantil-Cuantil:
  - La *probabilidad acumulada* (también llamada *función de distribución acumulada*) de una variable aleatoria X se define de la forma siguiente:
    - $F_x(x) = \text{Prob}\{X \leq x\}$.
  - Por ello, si los datos experimentales $x_1, \ldots, x_n$ están distribuidos de la misma forma que la variable aleatoria X, una aproximación razonable a $F_x(x)$ es la proporción de los datos experimentales que son menores o iguales que x.
  - Cabría pues, plantearse comparar la distribución de probabilidad acumulada obtenida a partir de los datos experimentales, con las distribuciones de probabilidad acumulada de las distribuciones estándar.

Tema 3: Modelado de las distribuciones de probabilidad de entrada

- Introducción
- Selección de la familia de distribuciones
- **Estimación de los parámetros**
- Medida de la bondad del ajuste
- Selección de la distribución en ausencia de datos

uja. Universidad de Jaén

Estimación de los parámetros

- Una vez seleccionada una familia de distribuciones, hay que escoger aquella distribución en concreto de la familia que mejor se ajusta a los datos experimentales.
- La forma de seleccionar la distribución es asignar valor a los parámetros de la distribución.
- Existen diferentes métodos de estimar el valor de los parámetros.
- Nosotros discutiremos sólo uno de ellos: los *estimadores de máxima verosimilitud*.

Estimación de los parámetros

Estimadores de máxima verosimilitud.

- Los fundamentos del método se comprenden mejor en el caso discreto.
- Se pretende ajustar a los datos experimentales la probabilidad $p_X(x,\theta)$ de cierta distribución discreta, donde θ es el parámetro cuyo valor quedará determinado por el ajuste.

Estimación de los parámetros

Estimadores de máxima verosimilitud.

- La *función verosimilitud*, $L(\vartheta)$, se define a partir de los datos experimentales $x_1, \ldots, x_n$ (los mismos usados en la Selección de la familia de distribuciones) de la manera siguiente:
  - $L(\vartheta) = p_X(x_1, \vartheta) \bullet p_X(x_2, \vartheta) \bullet \ldots \bullet p_X(x_n, \vartheta)$
- El estimador de máxima verosimilitud, $\hat{\vartheta}$, del parámetro desconocido , se define como el valor de ϑ que maximiza $L(\vartheta)$ para todos los valores permitidos de ϑ.

Estimación de los parámetros

Estimadores de máxima verosimilitud.

- El estimador de máxima verosimilitud es único para los parámetros de la mayoría de las familias de distribuciones, es decir, no hay varios valores del parámetro para los cuales se obtenga el mismo valor de la función verosimilitud y éste sea máximo.
- Generalmente los estimadores máximo-verosímiles pueden obtenerse mediante métodos de cálculo, ya que el máximo relativo de la función de verosimilitud obtenido diferenciando $L(\vartheta)$ con respecto a ϑ e igualando la derivada a cero es generalmente el máximo absoluto.

Tema 3: Modelado de las distribuciones de probabilidad de entrada

- Introducción
- Selección de la familia de distribuciones
- Estimación de los parámetros
- **Medida de la bondad del ajuste**
- Selección de la distribución en ausencia de datos

uja.
Universidad de Jaén

Medida de la bondad del ajuste

- Una vez estimados los parámetros de la distribución a partir de los datos experimentales $x_1, \ldots, x_n$, cabe preguntarse en qué medida los datos experimentales responden a la distribución ajustada, $\hat{F}_X(x)$.

Medida de la bondad del ajuste

- Para intentar responder a esta pregunta se usan técnicas gráficas y tests estadísticos.
- Los *tests de ajuste* pretenden contrastar la hipótesis siguiente:
  - H_0: Las observaciones $x_1, \ldots, x_n$ están distribuidas $\hat{F}_X(x)$.
- Hay que tener en cuenta que la mayoría de los tests no son demasiado potentes:
  - Cuando se dispone de pocas observaciones son poco sensibles a discrepancias entre los datos y la distribución ajustada
  - Cuando se dispone de muchas observaciones una pequeña discrepancia puede hacer que se rechace el ajuste.

Medida de la bondad del ajuste

- La bibliografía sobre tests de ajuste es muy extensa, en este tema únicamente nos referiremos a dos de ellos: el *test chi-cuadrado* y el *test de Kolmogorov-Smirnov* .
- La decisión acerca de cuál de estos dos tests usar depende de la naturaleza de la distribución y del tamaño de la muestra $x_1, \ldots, x_n$.

Medida de la bondad del ajuste

- El test de Kolmogorov-Smirnov es sólo válido para distribuciones continuas, mientras que el test chi-cuadrado es aplicable tanto a distribuciones discretas como continuas.
- El test chi-cuadrado requiere la clasificación de los datos de la muestra en clases.
- Dado que se recomienda que haya al menos 5 observaciones por clase y conviene tener un número razonablemente grande de clases, el test chi-cuadrado no es aplicable a muestras pequeñas.
- Por el contrario, el test de Kolmogorov-Smirnov es aplicable a cualquier tamaño de muestra.

Tema 3: Modelado de las distribuciones de probabilidad de entrada

- Introducción
- Selección de la familia de distribuciones
- Estimación de los parámetros
- Medida de la bondad del ajuste
- **Selección de la distribución en ausencia de datos**

uja. Universidad de Jaén

Selección de la distribución en ausencia de datos

- En algunos estudios de simulación, no se dispone de datos para estimar la distribución de probabilidad de las entradas aleatorias.
- Discutiremos algunas recomendaciones que pueden ayudar a seleccionar la distribución en ausencia de datos.

Selección de la distribución en ausencia de datos

- Si el proceso tiene muy poca variabilidad y se conoce su valor medio, puede sustituirse en el modelo la entrada aleatoria por un parámetro determinista cuyo valor sea el valor medio.
- Cuando un proceso estocástico de llegada cumple determinadas condiciones, suele usarse una distribución exponencial para generar los intervalos de tiempo entre llegadas sucesivas.
- Las distribuciones exponenciales deben usarse con cautela, ya que tienen una variabilidad muy grande.
  - Normalmente una distribución exponencial no resulta adecuada para modelar tiempos de servicio, ya que frecuentemente la duración de los mismos no tiene una variabilidad tan grande como representa la distribución exponencial.

Selección de la distribución en ausencia de datos

- Si se conoce la media y se sabe que la variabilidad del proceso es cierto porcentaje de la misma, puede usarse en primera aproximación una distribución uniforme o triangular simétrica.
  - Por ejemplo, si se sabe que la media es 100 y que la variabilidad está entorno al 30%, puede usarse U(70, 130) o bien triang (70, 130, 100).

Selección de la distribución en ausencia de datos

- En algunos casos se conocen los valores máximo y mínimo del proceso. Dependiendo de la naturaleza del proceso, puede usarse una distribución triangular con la media en el punto central del rango.
- Cuando sólo se conocen los extremos del rango, algunos autores recomiendan usar una distribución uniforme. Sin embargo, es difícil imaginar una situación real en la cual el tiempo de servicio, el intervalo entre llegadas o entre averías de una máquina, etc., esté uniformemente distribuido.

Selección de la distribución en ausencia de datos

- En algunos casos se conocen los valores máximo y mínimo del proceso. Dependiendo de la naturaleza del proceso, puede usarse una distribución triangular con la media en el punto central del rango.
- Cuando sólo se conocen los extremos del rango, algunos autores recomiendan usar una distribución uniforme. Sin embargo, es difícil imaginar una situación real en la cual el tiempo de servicio, el intervalo entre llegadas o entre averías de una máquina, etc., esté uniformemente distribuido.

Selección de la distribución en ausencia de datos

- Cuando se conoce el mínimo, el máximo y el modo (valor más probable del proceso, es decir, el máximo de la densidad de probabilidad), posiblemente las mejores opciones son usar la distribución triangular, la beta o la normal.
- La distribución triangular es la más cómoda de usar, ya que el máximo, mínimo y el modo son directamente los parámetros de la distribución.
- Otra posibilidad es la distribución beta: se usa frecuentemente para modelar el tiempo requerido para completar una tarea.

Tema 3: Modelado de las distribuciones de probabilidad de entrada

Diseño de modelos de simulación

4º Curso, 1er. Cuatrimestre - Grado en Ingeniería informática

Escuela Politécnica Superior de Jaén

Curso 2026-27

uja.
Universidad de Jaén